

Reporte 3: Capítulos I y II de Hands-On Machine Learning

Sebastián Aguilar Benavides

Nota. Lo hice como un tipo de resumen de conceptos, considero que me servirá para leerlo y tener dichos conceptos más presentes.

Sobre la definición de lo que es machine learning, me gustó bastante el concepto que le da Tom Mitchell, donde dice que una computadora se aprende si su rendimiento mejora con la experiencia. Esto me parece que es lo mismo que los humanos, viéndolo de esta manera: si a medida que tenemos más experiencia no mejoramos, ¿realmente aprendimos?

Términos:

- **Exactitud (*accuracy*):** clasificados correctamente (princ. clasificación)
- **Minería de datos (*data mining*):** Aplicar técnicas de ML para escarbar en grandes cantidades de datos puede ayudar a descubrir patrones que no eran evidentes de inmediato
- **Aprendizaje supervisado:** los datos de training que se le da al algoritmo incluyen las soluciones deseadas, llamadas etiquetas. Los modelos den a aprender a clasificar los nuevos datos que se les da, en base a los iniciales que tenían etiquetas.
- **Aprendizaje no supervisado:** los datos de entrenamiento no están etiquetados. El sistema intenta aprender sin una guía específica.
- **Reducción de dimensionalidad (PCA):** simplificar los datos sin perder demasiada información. Una forma de hacerlo es fusionar varias características correlacionadas en una sola.
- **Detección de anomalías:** Al sistema se le muestran principalmente instancias normales durante el entrenamiento, así que aprende a reconocerlas, y cuando ve una instancia nueva puede decir si se parece a una normal o si probablemente es una anomalía.
- **Ruido de muestreo:** poca cantidad de datos en la muestra que usa el modelo.

- **Reinforcement Learning (aprendizaje por refuerzo):** El agente puede observar el entorno, seleccionar y realizar acciones, y recibir recompensas o penalizaciones a cambio. Aprende por sí mismo y aplica las políticas en las situaciones dadas.

Retos del Machine Learning:

- **Cantidad Insuficiente de Datos de Entrenamiento:** Los algoritmos requieren miles de datos para aprender
- **Datos de Entrenamiento No Representativos:** Para generalizar bien, los datos de entrenamiento deben ser representativos de los nuevos casos a los que se desea generalizar
- **Datos de Baja Calidad:** datos de entrenamiento llenos de errores, valores atípicos y ruido (preprocesamiento).
- **Características Irrelevantes:** basura entra, basura sale (*garbage in, garbage out*). Selección de características: elegir las características más útiles, combinar características existentes para producir una más útil (PCA).
- **Sobreajuste de los Datos de Entrenamiento (Overfitting):**
- **Underfitting de los Datos de Entrenamiento:** el modelo es demasiado simple para aprender la estructura subyacente de los datos. Seleccionar un modelo más potente, con más parámetros, Darle mejores características al algoritmo de aprendizaje.

Se hicieron varios modelos, ¿cómo escoger el mejor?

1. Al modelo primero el training set
2. Luego el validation set
3. Se selecciona el mejor modelo según los resultados con el validation set
4. Se entrena dicho modelo con ambos sets juntos (training y validation) y se obtiene el modelo final